

ALGORITMOS GENÉTICOS

- O que são os algoritmos genéticos (GAs)?
- Qual a relação de GA com a genética e a evolução natural ?
- Como opera um GA em termos computacionais ?
- Quais as aplicações de GAs ?

Componentes de um Algoritmo Genético

1. Problema
2. Representação
3. Decodificação
4. Avaliação
5. Operadores
6. Técnicas
7. Parâmetros

1. PROBLEMA

GAs são indicados em problemas complexos de otimização:

- **muitos parâmetros e variáveis;**
- **mal estruturados: com condições e restrições, difíceis de serem modeladas matematicamente;**
- **grandes espaços de busca.**



2. REPRESENTAÇÃO

Representação é fundamental na modelagem de um GA e deve:

- descrever o espaço de busca relevante ao problema;
- codificar geneticamente a “essência” do problema:
evolução do “código” ➡ **evolução da solução**
- compatível com os operadores (crossover e mutação)
representação adequada ➡ **sucesso, evolução**

Tipos de Representação

- Binário
- Binário codificando Real
- Inteiro
- Real
- Estruturas: Vetores, Listas, Matrizes etc




BINÁRIO CODIFICANDO REAL

O binário é um contador das unidades mínimas de precisão


Aspectos importantes:

- ★ **variáveis** do problema $(x_1, x_2, \dots, x_t)$
- ★ **domínio** de valores: $x_i \in (\text{mín}_i, \text{máx}_i)$ em $\mathbb{R}$
- ★ **precisão**: p casas decimais

$(\text{máx}_i - \text{mín}_i) \times 10^p$ unidades de precisão



Representação:



onde,

$$2^{k_i} \geq (\text{máx}_i - \text{mín}_i) \times 10^p \Rightarrow \text{Precisão} = \frac{(\text{máx}_i - \text{mín}_i)}{2^{k_i} - 1}$$

Decodificação para Real:

$$x_{i \text{ real}} = x_{i \text{ bin}} \cdot \frac{(\text{máx}_i - \text{mín}_i)}{2^{k_i} - 1} + \text{mín}_i$$

$$\begin{aligned} \text{se } x_{i \text{ bin}} &= (0 \ 0 \ \dots \ 0) & \Rightarrow & \quad x_{i \text{ real}} = \text{mín}_i \\ \text{se } x_{i \text{ bin}} &= (1 \ 1 \ \dots \ 1) & \Rightarrow & \quad x_{i \text{ real}} = \text{máx}_i \end{aligned}$$



(0011011) Intervalo [0 ,10] precisão de 1 casa decimal

K= 7 (bits)

$$X_{\text{real}} = 27 * 10 / (2^7 - 1) + 0 = 270 / 127 = 2,12598$$

REPRESENTAÇÃO BINÁRIA


- ✱ simples de criar e manipular
- ✱ produz bons resultados
- ✱ facilita aplicações de operadores
- ✱ fácil decodificação numérica (inteiro, real)
- ✱ facilita a demonstração de teoremas
- ✱ porém, nem sempre é adequada



3. DECODIFICAÇÃO

Construir a solução para o problema a partir de um cromossoma:

Cromossomas “representam” soluções.

<u>Cromossoma</u>	<u>Transformação</u>	<u>Solução</u>
0011011	bin $\rightarrow$ inteiro	$x=27$
0011011	$x=27 \times 10/2^7 - 1$	$x=2,1 \quad x \in [0,10]$ 1 casa decimal
ADBCE		ADBCE ($\Sigma \text{dist.} = 18$)




4. AVALIAÇÃO

Elo entre o algoritmo genético e o problema.

$f(\text{cromossoma})$ = medida numérica de aptidão

Chances de seleção são proporcionais à aptidão.



5. OPERADORES

Atuam no processo de criação de novos indivíduos (descendentes):

1. Crossover
2. Mutação
3. Inversão
4. Operadores específicos ao problema

6. TÉCNICAS

- Técnicas de Representação
- Técnicas de Inicialização da População
- Técnicas de Eliminação da População Antiga
- Técnicas de Reprodução
- Técnicas de Seleção de Genitores
- Técnicas de Aptidão
- Técnicas de Parametrização
- Técnicas de Elitismo
- Técnicas de Seleção de Operadores

7. PARÂMETROS

- TAMANHO_POPULAÇÃO
- TOTAL_INDIVÍDUOS
- NÚMERO_GERAÇÕES
- TAXA_CROSSOVER
- TAXA_MUTAÇÃO
- APTIDÃO_OPERADORES
- ETC.



Desenvolvimento de um Algoritmo Genético

```
procedure algoritmo_genético
```

```
begin
```

```
    t = 0 ; primeira geração
```

```
    inicializa P(t) ; população inicial aleatória
```

```
    avalia P(t) ; calcula f(i) p/ cada indivíduo
```

```
    while (not condição_parada) do
```

```
        begin
```

```
            t = t + 1 ; próxima geração
```

```
            seleciona P(t) de P(t-1)
```

```
            altera P(t) ; crossover e mutação
```

```
            avalia P(t) ; calcula f(i) p/ cada indivíduo
```

```
        end
```

```
end
```



Desenvolvimento de um Algoritmo Genético

procedure algoritmo_genético

begin

$t = 0$; primeira geração

 inicializa $P(t)$; população inicial aleatória

 avalia $P(t)$; calcula $f(i)$ p/ cada indivíduo

 while (not condição_parada) do

 begin

$t = t + 1$; próxima geração

 seleciona $P(t)$ de $P(t-1)$

 altera $P(t)$; crossover e mutação

 avalia $P(t)$; calcula $f(i)$ p/ cada indivíduo

 end

end



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

Técnica Eliminação da População:

Elimina todos

Técnica de Reprodução:

Troca da geração

Técnica de Seleção de Genitores:

Roleta

Técnica de Aptidão:

Aptidão é a avaliação

Técnica de Parametrização:

Nenhuma

Técnica de Elitismo:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Use o primeiro

Operadores:

Crossover 1 ponto & mutação

Taxa Mutação:

0,008

Taxa Crossover:


0,65

Técnica de Parametrização:

nenhuma




Função F6



Função $F6(x,y)$

$F6(x,0)$



x

Características da F6

$$F6(x,y) = 0,5 - \frac{(\sin \sqrt{x^2 + y^2})^2 - 0,5}{(1,0 + 0,001 (x^2 + y^2))^2}$$

- Objetivo: Maximizar F6
- Uma única solução ótima: $F6(0,0)=1$
- Difícil de otimizar: vários mínimos locais



Representação

- Binária
- 2 Variáveis: x, y
- Domínio: $x, y \in [-100, +100]$
- Precisão: 4 a 5 casas decimais
- $\log_2 2 \times 10^6 \leq K_i \leq \log_2 2 \times 10^7$
- $K_i = 22 \rightarrow$ total de 44 bits



X e Y [-100,100] precisao de 4 a 5 casas decimais

$$2^k \geq (\text{Max}-\text{Min}) \cdot 10^p$$

$$(\text{Max}-\text{Min}) \cdot 10^p \geq 2^k \geq (\text{Max}-\text{Min}) \cdot 10^p$$

$$(100-(-100)) \cdot 10^4 \geq 2^k \geq (100-(-100)) \cdot 10^5$$

$$200 \cdot 10^4 \geq 2^k \geq 200 \cdot 10^5$$

$$2 \cdot 10^6 \geq 2^k \geq 2 \cdot 10^7$$

$$\text{Log}_2(2 \cdot 10^7) \geq k \geq \log_2(10^7)$$

Exemplo

- **Cromossoma:**

00001010000110000000011000101010001110111011

- **Dividido em x e y:**

0000101000011000000001 1000101010001110111011

- **Convertidos para base 10:**

165377 e 2270139

- **Multiplicados por: $200/2^{22}-1$**

7,885791751335085 e 108,24868875710696

- **Subtraídos de mín:**

$x=-92,11420824866492$ e $y=8,248688757106959$

- **Aplicados a $F6(x,y)$:**

$F6(x,y)=0,5050708$



Módulo de População

- Técnica Inicialização da População: *Aleatória*
 - ➔ *Geração aleatória de palavras de 44 bits*
- Técnica Eliminação da População: *Elimina todos*
 - ➔ *Elimina pop_size indivíduos da população anterior*
- Técnica de Reprodução: *Troca da geração*
 - ➔ *Reproduz pop_size indivíduos para a nova população*
- Técnica de Aptidão: *Aptidão é a avaliação*
 - ➔ *Aptidão é numericamente igual à avaliação*
- Técnica de Seleção de Genitores: *Roleta*



Parâmetros

- | | |
|---------------------------------------|---------|
| ● Tamanho da População: | Exemplo |
| pop_size | 100 |
| ● Número de Gerações: | |
| num_ger | 40 |
| ● Total de Indivíduos: | |
| total_ind = pop_size x num_ger | 4000 |



Seleção pela Roleta

Objetivo: *Selecionar indivíduos aleatoriamente, proporcionando maiores chances de reprodução aos mais aptos.*

Método por Computador

- Encontre a soma da aptidão de todos os membros da população $A_T = \sum A_i$ ($0 \leq i \leq \text{pop_size}-1$)
- Gere um número aleatório $0 \leq \text{rand} \leq A_T$
- Pegue o primeiro membro da população I_k cuja aptidão somada às aptidões dos membros precedentes é maior ou igual a rand.

$$\sum A_i \geq \text{rand} \quad (i < k)$$



Seleção pela Roleta

Objetivo: *Selecionar indivíduos aleatoriamente, proporcionando maiores chances de reprodução aos mais aptos.*

Método por Computador

- Encontre a soma da aptidão de todos os membros da população $A_T = \sum A_i$ ($0 \leq i \leq \text{pop_size}-1$)
- Gere um número aleatório $0 \leq \text{rand} \leq A_T$
- Pegue o primeiro membro da população I_k cuja aptidão somada às aptidões dos membros precedentes é maior ou igual a rand.

$$\sum A_i \geq \text{rand} \quad (i < k)$$



Exemplo da Roleta

Cromossoma

Aptidão


ΣA_i

1	2	3	4	5	6	7	8	9	10
8	2	17	7	2	12	11	7	3	7
8	10	27	34	36	48	59	66	69	76

Número Aleatório

Selecionado

23	49	76	13	1	27	57
3	7	10	3	1	3	7



Módulo de Reprodução

- Técnica de Seleção de Operadores: *Use o primeiro*
 - ➔ *Use o primeiro operador da lista de operadores*
- Operador: *Crossover & Mutação*
 - Taxa Mutação: *0,008*
 - Taxa Crossover: *0,65*
- *Valores ideais das taxas são obtidos experimentalmente*

Mutação

- Substitui cada bit de um cromossoma se o teste de probabilidade for verdadeiro
- Taxa Mutação: **0,8 % (0,008)**
- Alguns operadores podem sortear o novo bit:
 - **taxa efetiva = taxa x 0,5**

Cromossoma				Número Aleatório				Sorteio	Novo Cromossoma			
1	0	1	0	0,801	0,102	0,266	0,373	-	1	0	1	0
1	1	0	0	0,128	0,96	0,005	0,84	0	1	1	0	0
0	0	1	0	0,768	0,473	0,894	0,001	1	0	0	1	1

Crossover

- Partes de dois cromossomas genitores são trocadas a partir de uma posição escolhida aleatoriamente
- Taxa de Crossover : **65%**
 - Teste Verdadeiro → **Efetua Cruzamento**
 - Teste Falso → **Copia os Genitores**

P_1	1	0	1	1	0	1
P_2	0	0	1	1	0	0
F_1	1	0	1	1	0	0
F_2	0	0	1	1	0	1

ponto de corte aleatório ➤



Evolução X Convergência

- **Crossover:**

- acelerador do processo de busca
- tira proveito das soluções mais promissoras

- **Mutação**

- operador exploratório
- dispersa a população pelo espaço de busca

- **Convergência**

- população com indivíduos muito similares
- não há mais evolução:
 - ótimo encontrado ou convergência prematura
- para continuar a evoluir é preciso introduzir mais diversidade na população



Análise de Desempenho

- Melhor de um Experimento (valor)
- Curva dos Melhores por Geração
- Curva da Média de Melhores de Vários Experimentos



Média de Experimentos

- Calcula a média dos **melhores indivíduos** por geração em vários experimentos.
- Mede o desempenho do GA em encontrar uma solução melhor na geração seguinte
- GAs são estocásticos: desempenho varia a cada experimento
- São necessários muitos experimentos para se conhecer o desempenho médio do modelo de GA.

$$\overline{A}(t) = \frac{\sum_e^e A_e(t)}{\#_Experimentos} \quad 1 \leq e \leq \#_Experimentos$$

t : geração

$A_e(t)$: aptidão do melhor indivíduo em t no experimento e


$\overline{A}(t)$: média em $\#_Experimentos$ das aptidões dos melhores indivíduos a cada geração t



Média de Experimentos


	Experimentos				
	Melhores nas gerações				
	1º	2º	3º	4º	Média
ger 1	0,6	0,5	0,8	0,5	0,60
ger 2	0,7	0,5	0,8	0,7	0,68
ger 3	0,7	0,6	0,9	0,7	0,73
ger 4	0,8	0,6	0,9	0,8	0,78

Média de Experimentos



Característica da Curva de Desempenho

- bom desempenho no início da evolução
- pouco ou nenhum desempenho no final



Curva Média de Experimentos para $F6(x,y)$

- Usamos o número de dígitos 9 após o ponto decimal para distinguir avaliações muito próximas de 1,00 .
- Exemplo:

Avaliação	dígitos 9
0,99873578	2
0,82435787	0
0,99995432	4



ICADEMO

Características da Execução

Total de indivíduos: 4000 * (Máx: 15000)

População: 100 * (Máx: 300)

Taxa de Crossover (%): 65 * (Máx: 100%)

Taxa de Mutação (%): 0.0 * (Máx: 100%)

Total de Rodadas: 20 * (Máx: 100)

Características do Algoritmo

☐ Normalização Linear

☒ Elitismo

☐ Steady State

☐ Steady State w/ duplicados

☐ Nenhuma das características acima

Tipo de Crossover


☒ One Point ☐ Two Point ☐ Uniform

Min: 1 Máx: 100 Gap: 25

Atualizar: 0.000000, X=-0.00002, Y=-0.00004, Rodada 3

Desempenho do G.A.

Número de 9s Após o Ponto Decimal



Indivíduos Criados

Rodada Atual

Elemento: 3500

Valor: 0.9627758

X: 4.0756951

Y: -4.7740232

Controles

Iniciar

Imprimir...

Executar

- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

Técnica Eliminação da População:

Elimina todos

Técnica de Reprodução:

Troca da geração

Técnica de Seleção de Genitores:

Roleta

Técnica de Aptidão:

Aptidão é a avaliação

Técnica de Parametrização:

Nenhuma

Técnica de Elitismo:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Use o primeiro

Operadores:

Crossover 1 ponto & mutação

Taxa Mutação:

0,008

Taxa Crossover:

0,65

Técnica de Parametrização:

nenhuma

GA1-1

ICADEMO



Novas Técnicas e Parâmetros

- Técnicas de Aptidão
- Elitismo
- Reprodução Steady State
- Ajuste dos Parâmetros



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

➤ Técnica Eliminação da População:

Elimina o último

➤ Técnica de Reprodução:

Steady State s/ duplicados

Técnica de Seleção de Genitores:

Roleta

➤ Técnica de Aptidão:

Normalização Linear (100 a 1)

Técnica de Parametrização:

Nenhuma

Técnica de Elitismo:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Use o primeiro

Operadores:

Crossover 1 ponto & mutação

➤ Taxa Mutação:

0,04

➤ Taxa Crossover:

0,8

Técnica de Parametrização:

nenhuma



Medida de Aptidão

- O que ocorre se alteramos a F6 para:

$$F6(x,y) = 0,5 - \frac{(\sin \sqrt{x^2 + y^2})^2 - 0,5}{(1,0 + 0,001 (x^2 + y^2))^2}$$

Medida de Aptidão

- O que ocorre se alteramos a F6 para:

$$F6_{Elevada}(x,y) = 999,5 - \frac{(\text{sen } \sqrt{x^2 + y^2})^2 - 0,5}{(1,0 + 0,001 (x^2 + y^2))^2}$$

- Formato F6 = formato F6 elevada
- Melhor cromossoma para F6 = melhor para F6 elevada
- Avaliação de F6 elevada = avaliação F6 + 999
- ➔ **Todavia, GA 1-1 para $F6_{Elevada}$ não apresenta desempenho algum.**
- ➔ **PORQUE?**



Aptidão = Avaliação

$A_i = f_i$: aptidão do indivíduo i

$p_i = A_i / A_T = f_i / \sum f_j$: chances de seleção de i

há pop_size sorteios, então

$D_i = p_i \times \text{pop_size} = (f_i \times \text{pop_size}) / \sum f_j =$

$D_i = f_i / f_{AV}$: número provável de sorteios de i , ou
número de descendentes na próxima
geração

● F6 avaliação

best 0,979

worst 0,066

average 0,514

● $D_{best} = 1,905$

● $D_{worst} = 0,128$

➔ forte pressão seletiva em favor do melhor

● F6_{Elevada} avaliação

best 999,979

worst 999,066

average 999,514

● $D_{best} = 1,0005$

● $D_{worst} = 0,9996$

➔ melhor e pior cromossomas vão gerar o mesmo número de descendentes

O efeito da seleção é quase nulo porque as avaliações estão relativamente muito próximas.



Técnicas de Aptidão

- Aptidão é a Avaliação

$$A_i = f_i$$

Exemplo: $A_i = 999,979$

- Windowing

- subtrair uma constante dos valores de f_i

- Normalização Linear

- atribuir valores a A_i baseados no rank do cromossoma



Windowing

- Obtenha a avaliação mínima na população.
- Atribua a cada cromossoma i uma aptidão igual a:

$$A_i = (f_i - A_{\text{mín}})$$

- Opcionalmente, atribua uma aptidão mínima de “sobrevivência”, maior que a aptidão mínima calculada, como garantia de reprodução para os cromossomas menos aptos.
- Exemplo:

$$A_i = (999,979 - 999,066) = 0,913$$



Normalização Linear

- Coloque os pop_size cromossomas em ordem de crescente de avaliação (i=1 é o menos apto).
- Crie aptidões, partindo de um valor **mín** e crescendo lineamente até o valor **máx**.
- Os valores de **máx** e **mín** (ou a constante de incremento) são parâmetros da técnica.

$$A_i = \text{mín} + \frac{(\text{máx} - \text{mín})}{\text{pop_size} - 1} \times (i - 1)$$

- Quanto maior a constante de incremento, maior a pressão seletiva sobre os melhores.



Exemplo Comparativo

Rank dos cromossomas

Avaliação original

Aptidão é avaliação

Windowing: aptidão mín=0

Windowing: aptidão mín=10

Normalização. Linear taxa=1

Normalização taxa=20

6	5	4	3	2	1
200	9	8	8	4	1
200	9	8	8	4	1
199	8	7	7	3	0
199	10	10	10	10	10
100	99	98	97	96	95
101	81	61	41	21	1

- **SUPER INDIVÍDUO:** cromossoma 6

• poucas chance de recombinação com outros indivíduos; elimina competidores em poucas gerações; rápida convergência.

- **COMPETIÇÃO PRÓXIMA:** entre cromossomas 3, 4 e 5

• é preciso aumentar a pressão seletiva sobre os melhores



Comparação

- Aptidão é a Avaliação

- permite super indivíduo e competição próxima (sempre ocorre no final da evolução)

- Windowing

- ameniza a competição próxima (resolve problema da F6 elevada);
não resolve super indivíduo

- Normalização Linear

- impede domínio pelo super indivíduo; aumenta a competição nos grupos com avaliação próxima; evolui mais lentamente



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

Técnica Eliminação da População:

Elimina todos

Técnica de Reprodução:

Troca da geração

Técnica de Seleção de Genitores:

Roleta

➤ Técnica de Aptidão:

Normalização Linear (100 a 1)

Técnica de Parametrização:

Nenhuma

Técnica de Elitismo:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Use o primeiro

Operadores:

Crossover 1 ponto & mutação

Taxa Mutação:

0,008

Taxa Crossover:

0,65

Técnica de Parametrização:

nenhuma



Elitismo

- Melhor cromossoma de $P(t)$ é copiado em $P(t+1)$, após o mutação e crossover.
- Reduz o efeito aleatório do processo seletivo.
- Garante que o melhor indivíduo da próxima geração é melhor ou igual ao da geração anterior.



- **Módulo de Avaliação**

Função de Avaliação:

- **Módulo de População**

Técnica de Representação:

Técnica Inicialização da População:

Técnica Eliminação da População:

Técnica de Reprodução:

Técnica de Seleção de Genitores:

⇒ Técnica de Aptidão:

Técnica de Parametrização:

⇒ Técnica de Elitismo:

Population Size:

Total de Indivíduos:

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Operadores:

Taxa Mutação:

Taxa Crossover:

Técnica de Parametrização:

Função binária F_6

Binária 44 bits

Aleatória

Elimina todos

Troca da geração

Roleta

Normalização Linear (100 a 1)

Nenhuma

Copia o melhor

100

4000

Use o primeiro

Crossover 1 ponto & mutação

0,008

0,65

nenhuma

GA2-2

ICADEMO



Algoritmo Genético Tradicional

- Representação Binária
- Reprodução com substituição da população
- Elitismo
- Normalização Linear
- Crossover de 1 ponto e Mutação
 - Algoritmo de partida em aplicações
 - Apresenta bom desempenho em vários problemas



Reprodução Steady State

- Substituição parcial de indivíduos a cada geração (mais elitista)
- Bons indivíduos (material genético) são preservados, garantindo mais chances de reprodução
- Método:
 - Crie n filhos (seleção+crossover+mutação)
 - Elimine os n piores membros da população
 - Avalie e introduza os filhos na população
- **GAP** = fração da população que é trocada
- valor de GAP determina relação entre *exploitation* e *exploration*




Exemplo de Steady State

120
110
100
99
95
81
76
67
58
44
42
36
22
20
19
17
10
8
5

avaliação
em $P(t)$

38
6
121
88
58
17

crie n



120
110
100
99
95
81
76
67
58
44
42
36
22
38
6
121
88
58
17

substitua os n
piores

121
120
110
100
99
95
88
81
76
67
58
58
44
42
38
36
22
17
6

avaliação
em $P(t+1)$



- **Módulo de Avaliação**

Função de Avaliação:

- **Módulo de População**

Técnica de Representação:

Técnica Inicialização da População:

❖ Técnica Eliminação da População:

❖ Técnica de Reprodução:

Gap

Técnica de Seleção de Genitores:

❖ Técnica de Aptidão:

Técnica de Parametrização:

Population Size:

Total de Indivíduos:

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Operadores:

Taxa Mutação:

Taxa Crossover:

Técnica de Parametrização:

Função binária F_6

Binária 44 bits

Aleatória

Elimina o último

Steady State

Testar de 5 em 5

Roleta

Normalização Linear (100 a 1)

Nenhuma

100

4000

Use o primeiro

Crossover 1 ponto & mutação

0,008


0,65

nenhuma

GA2-3

ICADEMO





Steady State sem Duplicados

- Substituição parcial de indivíduos com **exclusão de duplicados**
- Evita os **duplicados que são mais frequentes** com steady state (populações mais estáticas)
- **Maior eficiência do paralelismo** de busca, garantindo pop_size indivíduos diferentes
- Descendentes duplicados são desprezados
- **Maior overhead para teste** de igualdade



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

➤ Técnica Eliminação da População:

Elimina o último

➤ Técnica de Reprodução:

Steady State s/ duplicados

Gap

Testar de 5 em 5

Técnica de Seleção de Genitores:

Roleta

➤ Técnica de Aptidão:

Normalização Linear (100 a 1)

Técnica de Parametrização:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Use o primeiro

Operadores:

Crossover 1 ponto & mutação

Taxa Mutação:

0,008


Taxa Crossover:

0,65

Técnica de Parametrização:

nenhuma





Variação dos Parâmetros

- Alterações nos parâmetros de um GA podem causar grande impacto no seu desempenho.
- GA 1-1: troca de geração, sem elitismo
 - ➡ requer taxas mais conservativas:
tx crossover=0,65; tx mutação=0,008
- GA 2-2 a 2-4: elitismo e steady state
 - ➡ mais crossover e mutação não implica em perda de bons cromossomas: tx crossover=0,7; tx mutação=0,01



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

➤ Técnica Eliminação da População:

Elimina o último

➤ Técnica de Reprodução:

Steady State s/ duplicados

Gap

Testar de 5 em 5

Técnica de Seleção de Genitores:

Roleta

➤ Técnica de Aptidão:

Normalização Linear (100 a 1)

Técnica de Parametrização:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

Use o primeiro

Operadores:

Crossover 1 ponto & mutação

➤ Taxa Mutação:

0,01


➤ Taxa Crossover:

0,7

Técnica de Parametrização:

nenhuma








Figure 2.1: Performance Graphs for GA 1-1, GA 2-1, GA 2-2, GA 2-3, GA 2-4, and GA 2-5



Algumas Conclusões

- Alterações no algoritmo afetam o desempenho de modo, muitas vezes, imprevisível.
- GA é estocástico ➡ raramente repete o mesmo desempenho em um experimento (fator sorte).
- Difícil de se reproduzir resultados obtidos por outros devido a detalhes de implementação.
- GAs são uma classe de método de busca de propósito geral (independente do domínio).
- GAs oferecem bom equilíbrio entre:
exploration X exploitation



Novos Técnicas, Parâmetros e Operadores

- Crossover de 2 pontos
- Crossover Uniforme
- Operadores Independentes e Seleção de Operadores
- Interpolação dos Parâmetros



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

Técnica Eliminação da População:

Elimina o último

Técnica de Reprodução:

Steady State s/ duplicados

Gap

Testar de 5 em 5

Técnica de Seleção de Genitores:

Roleta

Técnica de Aptidão:

Normalização Linear (100 a 1)

❖ Técnica de Parametrização:

Interpolar taxa de incremento (de 0,2 a 1,2)

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

❖ Técnica de Seleção de Operadores:

Roleta

❖ Operadores:

Crossover Uniforme

❖

Mutação

Taxa Mutação:

0,04

Taxa Crossover:

0,8

❖ Técnica de Parametrização:

Interpolar Pesos dos Operadores

❖

de (70 30) a (50 50)






Figure 3.1: Performance curves for GA 3-1, GA 3-2, and GA 3-3 on binary f6



Crossover de 2 Pontos

- Semelhante ao crossover de 1 ponto
- 2 pontos são escolhidos aleatoriamente
- Crossover de 1 ponto não consegue combinar todos os padrões de dois genitores

P_1	1	1	0	1	1	0	0	1	0	1	1	0	1	1
P_2	0	0	0	1	0	1	1	0	1	1	1	1	0	0
pontos de corte														
P_1	1	1	0	1	1	0	0	1	0	1	1	0	1	1
P_2	0	0	0	1	0	1	1	0	1	1	1	1	0	0
F_1	1	1	0	1	0	1	1	0	1	1	1	0	1	1
F_2	0	0	0	1	1	0	0	1	0	1	1	1	0	0

Crossover Uniforme

- A contribuição de cada genitor é decidida aleatoriamente por um padrão
- Capacidade de combinar quaisquer padrões

<i>P1</i>	1	0	0	1	0	1	1
<i>P2</i>	0	1	0	1	1	0	1
<i>Padrão</i>	1	1	0	1	0	0	1
<i>F1</i>	1	0	0	1	1	0	1
<i>F2</i>	0	1	0	1	0	1	1




Comparação dos Tipos de Crossover

- **Crossover de 1 e 2 pontos** são mais locais, tendem a preservar características codificadas compactamente.
- Portanto, quanto maior e mais dispersos o número de bits de um padrão, menores as chances de serem transmitidos intactos aos descendentes por crossover de 1 e 2 pontos.
- Crossover Uniforme, por outro lado, pode destruir bons padrões nos cromossomas.
- Seu efeito vai depender do grau de elitismo do modelo: steady state (GAP) ou substituição total.



Operadores Independentes

- Determinados GAs podem incorporar diversos operadores genéticos.
- Operadores não devem ser usados todos, com a mesma intensidade, a cada fase da evolução (*por ex: mais crossover no início e mais mutação no final da evolução*).
- Uma **roleta** sorteia **um operador** a cada reprodução.
- Pesos (chances) dos operadores, iniciais e finais, e taxa de interpolação são parâmetros do algoritmo.



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

Técnica Eliminação da População:

Elimina o último

Técnica de Reprodução:

Steady State s/ duplicados

Gap

Testar de 5 em 5

Técnica de Seleção de Genitores:

Roleta

Técnica de Aptidão:

Normalização Linear (100 a 1)

Técnica de Parametrização:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

⇒ Técnica de Seleção de Operadores:

Roleta

⇒ Operadores:

Crossover 2 pontos

⇒

Mutação

Taxa Mutação:

0,01

Taxa Crossover:

0,7

Técnica de Parametrização:

Nenhuma

⇒ Pesos

(50 50)



- **Módulo de Avaliação**

Função de Avaliação:

Função binária F_6

- **Módulo de População**

Técnica de Representação:

Binária 44 bits

Técnica Inicialização da População:

Aleatória

Técnica Eliminação da População:

Elimina o último

Técnica de Reprodução:

Steady State s/ duplicados

Gap

Testar de 5 em 5

Técnica de Seleção de Genitores:

Roleta

Técnica de Aptidão:

Normalização Linear (100 a 1)

Técnica de Parametrização:

Nenhuma

Population Size:

100

Total de Indivíduos:

4000

- **Módulo de Reprodução**

❖ Técnica de Seleção de Operadores:

Roleta

❖ Operadores:

Crossover Uniforme

❖

Mutação

Taxa Mutação:

0,01

Taxa Crossover:

0,7

Técnica de Parametrização:

Nenhuma


❖ Pesos

(50 50)




Desempenho

- Aspectos importantes:
 - convergência do GA
 - proximidade dos melhores cromossomas a um mínimo local
 - diversidade da população
 - valores dos parâmetros do GA
- Exemplo: variação da aptidão dos operadores durante evolução.




Início:

Crossover
Mutaç o



Meio:

Crossover
Mutaç o



Fim:

Crossover
Mutaç o



Interpolação de Parâmetros

- Consiste na variação dos valores dos parâmetros do GA durante a execução, de modo a alcançar maior desempenho.
- Parâmetros:
 - taxa de crossover
 - taxa de mutação
 - taxa incremento da normalização da aptidão
 - aptidão dos operadores
- Interpolação define:
 - valores inicial e final do parâmetro e frequência de ajuste.



- **Módulo de Avaliação**

Função de Avaliação:

- **Módulo de População**

Técnica de Representação:

Técnica Inicialização da População:

Técnica Eliminação da População:

Técnica de Reprodução:

Gap

Técnica de Seleção de Genitores:

Técnica de Aptidão:

➤ Técnica de Parametrização:

Population Size:

Total de Indivíduos:

- **Módulo de Reprodução**

➤ Técnica de Seleção de Operadores:

➤ Operadores:

➤

Taxa Mutação:

Taxa Crossover:

➤ Técnica de Parametrização:

➤

Função binária F_6

Binária 44 bits

Aleatória

Elimina o último

Steady State s/ duplicados

Testar de 5 em 5

Roleta

Normalização Linear (100 a 1)

Interpolar taxa de incremento (de 0,2 a 1,2)

100

4000

Roleta

Crossover Uniforme

Mutação

0,01

0,7

Interpolar Pesos dos Operadores

de (70 30) a (50 50)

GA3-3

ICADEMO

gráfico

