

Algoritmos Genéticos Híbridos

- Consiste na construção de um GA inspirado no “algoritmo de otimização em uso” em determinado problema (se houver).

Alg. Híbrido = Alg. Em Uso + Alg. Genético

- Híbridizar:
 - Adotar REPRESENTAÇÃO em uso
 - Adaptar OPERADORES
 - Adotar HEURÍSTICAS de otimização



Vantagens

- Modelo incorpora o **conhecimento** no domínio do problema;
- Resulta num **sistema mais familiar** para o usuário;
- Algoritmo em uso pode fornecer “sementes” para o GA, garantindo **soluções melhores**.
- Novos operadores devem estar alinhados com a filosofia de GAs: **recombinação e mutação**
 - **Crossover**: recombinação de sub-partes de indivíduos
 - **Mutação**: variações globais ou locais para manter agitada a variedade genética



Representação por Números Reais

Cromossomas são estruturas contendo números reais.

- Hibridizando com “algoritmo em uso” para a otimização da função $f_6(x,y)$
- “Algoritmo em uso” $\equiv$ Busca Exaustiva de x e y reais

- *Gera x e $y \in \mathcal{R}$ aleatoriamente;*
- *Calcula f_6 para o par (x,y) ;*
- *Salva (x,y) e $f_6(x,y)$;*
- *Retorna a melhor avaliação se tempo esgotado;*
- *Retorna ao primeiro passo;*



Hibridização

- Representação:
Lista de Reais : (x,y)
- Avaliação:
 $f6(x,y)$ real
- Inicialização:
Números reais aleatórios
- Operadores Genéticos:
Crossover e Mutação e
Operadores inspirados no problema

Crossover

- Cromossoma é uma lista de reais: (x,y)
- Crossover de 1 ou 2 pontos ou Uniforme sobre lista:
- Exemplo: Crossover Uniforme Problema com 4 variáveis

$$P_1 \equiv (x_1, y_1, t_1, z_1)$$

$$F_1 \equiv (x_2, y_1, t_1, z_2)$$



$$P_2 \equiv (x_2, y_2, t_2, z_2)$$

$$F_2 \equiv (x_1, y_2, t_2, z_1)$$

$$\text{Padrão} \equiv 0 \quad 1 \quad 1 \quad 0$$

Crossover de Média

- **Cruzamento específico para o problema**
- Se dois cromossomas são promissores, a média de seus valores reais pode levar a uma melhor solução

$$P_1 \equiv (x_1, y_1)$$

$$\Rightarrow F_1 \equiv ((x_1 + x_2)/2, (y_1 + y_2)/2)$$

$$P_2 \equiv (x_2, y_2)$$

- A média entre dois valores pode resultar em valores mais próximos do valor desejado

Crossover de Média

- Crossover aritmético é uma combinação linear de dois vetores (genitores) P_1 e P_2 na geração t :

$$F_1 = a \cdot P_1 + (1-a) P_2$$

$$F_2 = a \cdot P_2 + (1-a) P_1$$

- $a = \text{cte}$: crossover uniforme
- $a = f(t)$: crossover não-uniforme (a depende da idade da população)



Mutação

- **Mutação de real**

- substitui cada número real em um cromossoma por um número real aleatório (se teste probabilidade=TRUE)

$$(x_1, y_1) \Rightarrow (x_1, y_{\text{rand}})$$

- **Creep**

- busca uma solução próxima através de ajustes aleatórios em ambas as direções (+ e -)

$$(x_1, y_1) \Rightarrow (x_1 \pm \Delta x, y_1 \pm \Delta y)$$

$\Delta \equiv$ pequeno ou grande

Creep - Método de Ajuste 1

- $$X^{t+1} = \begin{cases} X^t + \Delta (\text{máx} - X^t) & \text{se bit sorteado} = 0 \\ X^t - \Delta (X^t - \text{mín}) & \text{se bit sorteado} = 1 \end{cases}$$

máx e mín = limites do domínio de x

- $\Delta(s) = s \cdot \text{rand}$

rand = número aleatório $\in [0, p]$, $p \leq 1$

- O ajuste varia com o valor de p:

se p = pequeno ➡ ajuste menor

se p = grande ➡ ajuste maior



Creep - Método de Ajuste 2

$$\bullet X^{t+1} = \begin{cases} X^t + \Delta(t, \text{máx} - X^t) & \text{se bit sorteado} = 0 \\ X^t - \Delta(t, X^t - \text{mín}) & \text{se bit sorteado} = 1 \end{cases}$$

t = geração; máx e mín = limites do domínio de x.

$$\bullet \Delta(t, s) = s \cdot (1 - \text{rand})^{(1 - \frac{t}{T})^b}$$

rand = número aleatório $\in [0, 1]$

T = número máximo de gerações

b = grau de dependência com o número da geração

- A probabilidade de $\Delta(t, s)$ ser próximo de zero aumenta com o número de gerações.



- **Módulo de Avaliação**

- ⇒ Função de Avaliação:

- **Módulo de População**

- ⇒ Técnica de Representação:

- ⇒ Técnica Inicialização da População:

Técnica Eliminação da População:

Técnica de Reprodução:

Gap

Técnica de Seleção de Genitores:

Técnica de Aptidão:

Técnica de Parametrização:

Population Size:

Total de Indivíduos:

- **Módulo de Reprodução**

Técnica de Seleção de Operadores:

- ⇒ Operadores:

- ⇒

- ⇒

- ⇒

- ⇒

- ⇒ Técnica de Parametrização:

- ⇒

Função F6 real

Lista de números reais

Números reais aleatórios

Elimina o último

Steady State s/ duplicados

Testar de 5 em 5

Roleta

Normalização Linear (100 a 1)

Interpolar taxa de incremento (0,2 a 1,2)

100

4000

Roleta

Crossover Uniforme de Lista

Crossover de Média

Mutação de Número Real

Creep Δ pequeno

Creep Δ grande

Interpolar Pesos dos Operadores

de (10 40 10 30 10) a (10 20 0 40 30)






Figure 5.2: Performance graphs for GA 3-3 and GA 5-1 on f6.

Binária x Reais

- Representação dos genes por números reais (ponto flutuante) é mais adequada em problemas de otimização de parâmetros com variáveis sobre domínio contínuo;
- Especialmente em grandes domínios onde a representação binária requer um longo cromossoma:
Ex: 100 variáveis, $[-500, 500]$, 4 casas decimais ➡ 2400 bits
- Representação por reais é mais rápida na execução;
- Representação por reais oferece maior precisão (depende do computador);
- Desempenho pode ser melhorado com operadores específicos ao problema;
- Representação por reais tem a propriedade que dois pontos próximos um ao outro no espaço de representação, estão também próximos no espaço do problema;
- Representação por reais evita Hamming Cliffs.



Distância de Hamming

- Rep. Binário Valor Real

$C_1 = 011111$ 31

$C_2 = 100000$ 32

➡ distância = 6

- Rep. Real Valor Real

$C_1 = 31$ 31

$C_2 = 32$ 32

➡ distância = 1



