

Back Propagation

Modelagem da Rede Neural

Modelagem da Rede Neural

• Limpeza de Dados:

- as transações podem conter valores incorretos, dados ausentes e inconsistências



- conhecimento sobre os limites dos dados;
- visualização para identificar “outliers”;
- uso de informação estatística para estabelecer como **neutros** os valores ausentes ou incorretos.

Modelagem da Rede Neural

• Fatores importantes para a modelagem da Rede Neural:

- ☑ Seleção de variáveis;
 - ☑ Limpeza dos dados;
 - ☑ Representação das variáveis de entrada e saída;
 - ☑ Normalização;
 - ☑ Buscando melhor Generalização
- ⇒ **validação cruzada**

Modelagem da Rede Neural

• Representação dos Dados:

- **Discretos** → deve ser transformado em uma representação que apresente um único conjunto de entradas para cada valor discreto
➢ 1 of N; binário; termômetro
- **Contínuos** → Escalonamento básico

Modelagem da Rede Neural

• Seleção de Variáveis:

- diminui o tamanho da rede
- acelera o aprendizado
- melhora a generalização da Rede



- combinação de variáveis (atributos):
 - razão, produto, soma ou diferença de 2 valores
- diversos métodos:
 - correlação; PCA (Principal Component Analysis); etc.

Representação - Discretos

• 1 of N

- # de entradas = # de categorias
- mais simples e mais fácil para a Rede Neural
- pode gerar muitas entradas
→ **piora a generalização**

Exemplo de 4 classes:

casado	⇒ 1000
solteiro	⇒ 0100
divorciado	⇒ 0010
viúvo	⇒ 0001

Representação - Discretos

- código binário

- N categorias representado por n bits ($N=2^n$)
- valores próximos podem ter distância de hamming grande na representação

Exemplos:

- 36 sintomas diferente $\Rightarrow$ 6 entradas ($2^6 = 64$)
- 12 meses do ano $\Rightarrow$ 4 bits de entrada ($2^4 = 16$)

Representação - Contínuos

- Escalonamento linear, se os valores estão uniformemente distribuídos na faixa de dados

Ex2: salários de 0 a 300.000 mas só preciso diferenciar salários até 35.000



linear por partes: 0 - 35.000 $\Rightarrow$ 0 a 1.0
35.000 - 300.000 $\Rightarrow$ 1.0

Representação - Discretos

- termômetro

- quando os dados estão relacionados de forma crescente ou decrescente

- Exemplo - 4 classes de salários:

baixo	$\Rightarrow$ 1000
bom	$\Rightarrow$ 1100
muito bom	$\Rightarrow$ 1110
excelente	$\Rightarrow$ 1111

Modelagem da Rede Neural

- Normalização

- escalonamento

- as redes geralmente aceitam valores entre 0/(-1) e 1
- linear $\Rightarrow$ se os dados estão uniformemente distribuídos
- não-linear $\Rightarrow$ logarítmico, etc

- normalização de vetores

- divide pela faixa máxima de valores
- menos processamento

$$x_i^n = \frac{x_i - \min}{\max - \min}$$

- subtrai do valor médio e divide pelo desvio padrão
- (sinal com média zero e variância unitária)

$$x_i^n = \frac{x_i - \bar{x}}{\sigma}$$

Representação - Contínuos

- Escalonamento linear, se os valores estão uniformemente distribuídos na faixa de dados

Ex1: variável salário [0, 100] (R\$100,00)
80% dos valores estão abaixo de 50




linear por partes: 0 - 50 $\Rightarrow$ 0 a 0.8
50-100 $\Rightarrow$ 0.8 a 1.0

GENERALIZAÇÃO

- Validação Cruzada:
- Qual o melhor critério de parada do treinamento?
 - Até que o erro de treinamento seja inferior a um certo valor especificado $\Rightarrow$ **super treinamento** (“overfitting”).

GENERALIZAÇÃO



GENERALIZAÇÃO


- Validação Cruzada:
- Na verdade, **k** configurações diferentes de treinamento e validação devem ser geradas (aleatoriamente), ficando fixo, geralmente, apenas o conjunto de teste $\Rightarrow$ **k-fold cross-validation**.
- Escolhe-se a rede treinada com o conjunto que forneceu o melhor desempenho de validação.
- A **variância** no desempenho fornece informação sobre a **sensibilidade da rede ao conjunto de treinamento apresentado**.

Conjunto de teste também é denominado **holdout**

GENERALIZAÇÃO

- Validação Cruzada:
- **super treinamento ("overfitting"):**
 - os pesos estão sendo modificados para ajustar também o ruído existente nos padrões de treinamento;
 - quanto maior o número de pesos, maior o problema de overfitting;
 - **weight decay** ajuda a reduzir esse problema;
 - Deve-se verificar o comportamento na generalização $\Rightarrow$ **necessita de um conjunto de validação!**

GENERALIZAÇÃO



GENERALIZAÇÃO

- Validação Cruzada:
- Deve-se dividir os padrões em três conjuntos:
 - **treinamento (estimação)** $\Rightarrow$ padrões usados para modificar os pesos;
 - **validação** $\Rightarrow$ padrões usados para verificar o problema de overfitting;
 - deve-se **guardar a configuração de pesos** que obteve, até o momento, **o melhor desempenho no conjunto de validação**.
 - **teste** $\Rightarrow$ padrões para testar o desempenho do modelo final.

GENERALIZAÇÃO

- Validação Cruzada:
- **Conclusão** $\Rightarrow$
 - O treinamento só deve ser interrompido quando o erro dos padrões do conjunto de validação começar a **subir de forma consistente**.

GENERALIZAÇÃO

- Validação Cruzada:

- Também é usado para determinar o número adequado de processadores na(s) camada(s) intermediárias.



- Da mesma forma, divide-se o conjunto de padrões em três subconjuntos: **estimação**, **validação** e **teste**.
- Treina-se diferentes arquiteturas com os padrões do conjunto de estimação e **escolhe-se aquela que apresentar o menor erro no conjunto de validação**.



GENERALIZAÇÃO

- Validação Cruzada:

- O que fazer quando o conjunto de padrões é pequeno?

- Particiona os m padrões disponíveis para treinamento e validação em k conjuntos disjuntos, cada um com m/k padrões;
- efetua-se o procedimento de *cross-validation* k vezes, cada vez utilizando um conjunto diferente para efetuar a **validação** e os outros $k-1$ para fazer o **treinamento**;
- determina-se para cada um o número ideal i de iterações;
- calcula-se a média das iterações i_m nos k experimentos;
- Executa-se um treinamento final, com os m padrões (sem padrões para validação) por i_m iterações.

Fim do Back Propagation